

week_12

≡ 태그

DL

트랜스포머

트랜스포머(Transformer)는 2017년 코넬 대학의 아시시 바스와니(Ashish Vaswani) 등이 발표한 「Attention is All You Need」 논문을 통해 소개된 신경망 아키텍처입니다. 기존 순환 신경망(RNN) 방식과 달리 셀프어텐션(Self-Attention) 메커니즘만으로 입력 토큰 간의 관계를 직접 모델링합니다.

핵심 특징

- 병렬 처리: 입력 시퀀스를 순차가 아닌 병렬로 처리 → 긴 시퀀스에서 RNN보다 훨씬 빠름
- Self-Attention: 순차 처리나 반복 연결 없이 토큰 간 관계를 직접 파악
- 대규모 학습 효율: 대용량 데이터셋에서 매우 효율적, 기계 번역·텍스트 요약 등에 탁월
- 장기 의존성 처리: 문장이 길어져도 전체 정보를 임베딩에 반영하여 성능 유지

학습 방식 구분

트랜스포머 기반 모델은 두 가지 학습 방식을 사용합니다.

오토 인코딩 (Auto-Encoding)	자기 회귀 (Auto-Regressive)
문장의 일부를 빈칸 토큰으로 만들고 해당 빈칸에 적절한 단어를 예측합니다. 예측 시 앞·뒤 토큰 모두 참조하므로 양방향(Encoder) 구조를 가집니다.	이전 단어들이 주어졌을 때 다음 단어를 맞추는 방식입니다. 예측되는 토큰의 왼쪽 토큰만 참조하므로 단방향(Decoder) 구조를 가집니다.

트랜스포머 기반 모델 비교

주요 트랜스포머 모델들의 구조와 학습 방식을 비교합니다.

모델	학습구조	학습방법	학습 방향성
BERT	인코더	오토 인코딩	양방향
GPT	디코더	자기 회귀	단방향

BART	인코더+디코더	오토 인코딩+자기 회귀	양방향+단방향
ELECTRA	인코더+판별기	오토 인코딩+대체 토큰 탐지	양방향
T5	인코더+디코더	오토 인코딩+자기 회귀+다양한 NLP 학습	양방향

어텐션 메커니즘 (Attention Mechanism)

트랜스포머는 순환·합성곱 신경망 대신 어텐션 메커니즘만으로 시퀀스 임베딩을 표현합니다. 인코더-디코더 간 상호작용을 통해 입력 시퀀스의 중요한 부분에 집중하여 문맥을 이해하고 적절한 출력을 생성합니다.

인코더와 디코더의 역할

인코더 (Encoder)	디코더 (Decoder)
입력 시퀀스를 임베딩하여 고차원 벡터로 변환합니다. 양방향으로 문맥을 파악합니다.	인코더의 출력을 입력으로 받아 출력 시퀀스를 생성합니다. 마스크 멀티 헤드 어텐션으로 인과성을 보장합니다.

입력 임베딩과 위치 인코딩

트랜스포머는 입력 시퀀스를 병렬로 처리하므로 단어의 순서 정보를 자체적으로 제공하지 않습니다. 이를 보완하기 위해 위치 인코딩(Positional Encoding)을 임베딩 벡터에 추가합니다.

위치 인코딩 수식

위치 인코딩은 sin/cos 함수를 사용해 각 위치마다 고유한 벡터를 생성합니다.

짝수 차원	$PE(pos, 2i) = \sin(pos / 10000^{2i/d_model})$
홀수 차원	$PE(pos, 2i+1) = \cos(pos / 10000^{2i/d_model})$

파라미터 설명

pos	입력 시퀀스에서 해당 단어의 위치
i	임베딩 벡터의 차원 인덱스
d_model	트랜스포머 모델의 임베딩 차원 크기

1/100002i/d_model	각 위치에 대한 주기적인 신호를 생성하는 스케일링 인자
-------------------	--------------------------------

트랜스포머 인코더

트랜스포머 인코더는 입력 시퀀스를 받아 여러 인코더 계층을 거쳐 연산을 수행합니다. 각 계층은 멀티 헤드 어텐션과 순방향 신경망(FFN)으로 구성되며, 입력 데이터에 대한 정보를 추출하고 다음 계층으로 전달합니다.

멀티 헤드 어텐션 (Multi-Head Attention)

입력 시퀀스에서 쿼리(Q), 키(K), 값(V) 벡터를 정의해 셀프 어텐션(Self-Attention)을 수행하는 핵심 연산입니다.

쿼리 (Query)	현재 시점에서 참조하고자 하는 정보의 위치를 나타내는 벡터. "지금 무엇을 찾고 있는가?"를 표현합니다.
키 (Key)	쿼리 벡터와 비교되는 대상으로, 입력 시퀀스에서 탐색되는 벡터. "나는 이런 정보를 갖고있다"를 표현합니다.
값 (Value)	쿼리·키로 생성된 어텐션 스코어를 얼마나 반영할지 설정하는 가중치 벡터. "실제로 전달할 정보의 내용"입니다

어텐션 스코어 계산

쿼리·키 벡터의 내적 연산으로 어텐션 스코어를 구하고, $\sqrt{d}$ (벡터 차원의 제곱근)만큼 나눠 보정한 뒤 소프트맥스를 적용합니다.

$$score(v^q, v^k) = softmax((v^q)^T \cdot v^k / \sqrt{d})$$

인코더 계층 처리 흐름

①	위치 임베딩 추가: 입력 임베딩에 위치 인코딩 벡터를 더합니다.
②	멀티 헤드 어텐션: Q·K·V 벡터를 생성하고 k개의 헤드로 셀프 어텐션 수행.
③	덧셈 & 정규화(Add & Norm): 잔차 연결 후 레이어 정규화로 기울기 소실 완화.
④	순방향 신경망(FFN): 선형 임베딩 + ReLU로 임베딩 벡터를 고도화
⑤	반복: N개의 인코더 블록을 통과하며 점차 정보를 추상화.

트랜스포머 디코더

트랜스포머 디코더는 위치 인코딩이 적용된 타겟 데이터의 입력 임베딩을 받아 처리합니다. 인코더와 유사하지만 마스크 멀티 헤드 어텐션(Masked Multi-Head Attention)을 사용해 인과성(Causality)을 보장합니다.

마스크 멀티 헤드 어텐션

어텐션 스코어 맵을 계산할 때 미래 위치의 토큰을 참조하지 못하도록 마스크를 씁니다. 마스크 영역에 수치적으로 매우 작은 inf 를 더해 소프트맥스 적용 시 해당 가중치가 0에 수렴하게 만듭니다.

마스크 적용 전	마스크 적용 후
모든 토큰 간의 어텐션 스코어를 계산합니다. 미래 시점 토큰도 참조 가능한 상태입니다.	미래 토큰 위치에 inf 마스크를 더합니다. softmax 후 해당 위치의 가중치는 0이 됩니다.

디코더의 처리 흐름

디코더는 타겟 데이터를 순차적으로 생성하는 과정을 반복합니다.

마스크 멀티 헤드 어텐션	타겟 시퀀스 내 이전 토큰들만 참조하여 자기 자신을 인코딩
멀티 헤드 어텐션	인코더의 키(K)·값(V) 벡터를 참조하여 소스 정보와 연결
순방향 신경망	어텐션 결과를 고도화
반복 (N블록)	여러 디코더 블록을 통과하며 최종 출력 생성
선형 + 소프트맥스	마지막으로 어휘 사전 크기의 예측 확률 분포 출력

특수 토큰

트랜스포머는 단어 토큰 이외에 특수 토큰을 활용하여 문장을 표현합니다. 이 특수 토큰은 입력 시퀀스의 시작과 끝을 나타내거나 마스크링(Masking) 영역으로 사용됩니다.

토큰	전체 이름	역할
	Beginning of Sentence	문장의 시작을 나타냅니다. 디코더 입력의 첫 토큰으로 사용됩니다.
	End of Sentence	문장의 종료를 나타냅니다. 이 토큰이 생성되면 디코

		딩을 멈춥니다.
	Padding	모든 문장을 동일한 길이로 맞추기 위해 짧은 문장의 빈 공간을 채웁니다.
	Unknown	어휘 사전에 없는 단어를 처리할 때 사용합니다.

토큰화 처리 흐름

문장 토큰 배열을 어휘 사전에 등장하는 위치에 원-핫 인코딩으로 표현한 후, 임베딩 행렬 $[V, d]$ 에 의해 $[1, d]$ 크기의 입력 임베딩으로 변환됩니다.

원문 텍스트	"ChatGPT는 트랜스포머 모델로 이뤄져 있다"
토큰화	[, ChatGPT, 는, 트랜스포머, 모델, 로, , 있다, , , ...]
원-핫 인코딩	각 토큰을 어휘 사전 크기(V)의 벡터로 변환 (해당 위치만 1)
입력 임베딩	원-핫 벡터 × 임베딩 행렬 $[V, d] \rightarrow [1, d]$ 벡터
위치 인코딩 추가	임베딩 벡터 + 위치 인코딩 벡터 → 최종 입력

GPT

GPT(Generative Pre-trained Transformer)는 2018년 OpenAI에서 발표한 트랜스포머 기반 언어 모델로 가장 널리 알려진 언어 모델입니다. ELMo와 같이 대규모 말뭉치로 사전 학습된 모델로, 다양한 다운스트림 작업에서 우수한 성능을 보입니다

GPT의 핵심 특징

디코더 기반	트랜스포머의 디코더를 여러 층 쌓은 언어 모델
단방향 처리	이전 단어들만 참조하는 자기 회귀(Auto-Regressive) 방식
사전 학습 + 파인튜닝	대규모 텍스트로 사전 학습 후, 다운스트림 태스크에 파인튜닝
텍스트 생성 특화	입력 문장과 출력 문장 간의 관계 이해 및 문장 생성에 집중

인코더 vs 디코더 모델 비교

구분	인코더 기반 (BERT)	디코더 기반 (GPT)
학습 방식	오토 인코딩 (마스킹)	자기 회귀 (다음 토큰 예측)
어텐션 방향	양방향	단방향 (왼쪽 → 오른쪽)

주요 용도	분류, NER, QA 등 이해 태스크	텍스트 생성, 요약, 번역
대표 모델	BERT, RoBERTa, ELECTRA	GPT-2, GPT-3, GPT-4